



캡스톤 디자인 최종 발표

협주 가능 악기 레슨 Agent AI 플랫폼 기술 개발

멀티에이전트 × Q-learning

● 음정 ● 박자 ● 자세

세 에이전트가 연주를 측정하며, Q-learning으로 액션(피드백)을 판단한다.

연주가 흐르는 동안, 마디 단위로 오디오, 비디오를 측정합니다



① 측정

마디가 끝날 때마다 음정·박자·자세
세 에이전트가 각자 영역을 측정해
상태(state)를 출력한다.



② 액션 선택

Q-learning 엔진이 그 상태에서
어떤 액션(피드백)을 줄지
선택해 화면으로 보낸다.



③ 슈퍼바이저 위임

개별 에이전트로 해결이 안 되는
상황이면, CALL_SUPERVISOR
액션이 선택된다.
LLM이 진짜 문제의 원인을 세
에이전트의 측정값을 종합해
판단하고 피드백을 화면으로
보낸다.

핵심 "개별 에이전트의 피드백이 소용없음을 학습된 Q-table로 확인하면, 슈퍼바이저 에이전트에게 위임한다.

핵심 설계 3가지



측정 ↔ 피드백 계층 분리

측정 모듈은 상태를 출력한다.
액션(피드백)은 정책 모듈로
분리하여 관리한다.

→ 응집도를 높히고 결합도를
낮춘다.



피드백과 개선 여부를
관리하는 Q-table 구조

슈퍼바이저를 호출은 개별
에이전트의 Q-table 값 비교로
정해진다.

슈퍼바이저에게 판단이 위임된
경우 LLM이 세 에이전트의
정보를 받아 맞춤형 피드백을
생성한다.

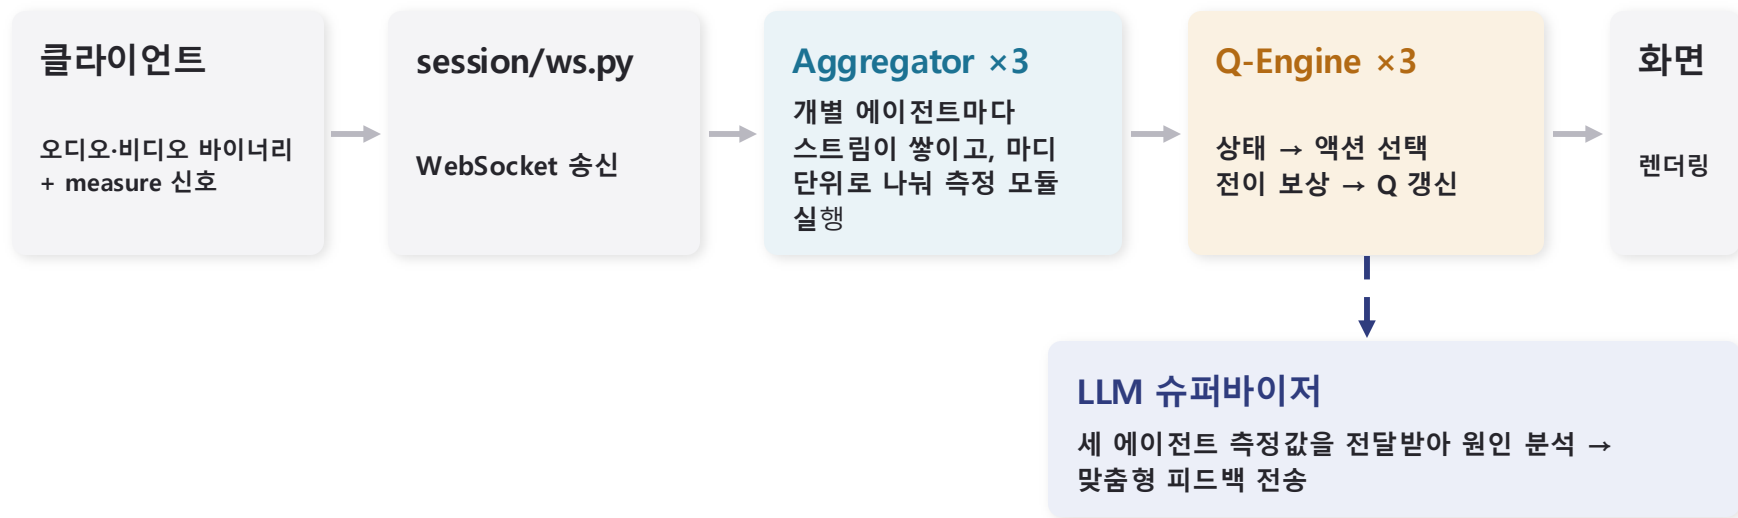


사용자 기반 누적 학습 효과

Q-table을 (user, domain,
state, action) 키로 DB에 남긴다.

→ 연주를 거듭할수
록 사용자에게 맞는
피드백 선택이 가능해지도록 누
적 학습된다.

종합 파이프라인



세션 완료 → MySQL

연주 완료: feedback_events INSERT + q_table_entries UPSERT (다음 연주는 학습된 Q-table로 시작)

연주 입력 데이터 (오디오, 비디오) 스트림

바이너리 프레임 [kind 1B] [ts_ms 4B] [payload]

0x01 오디오(PCM16) → 음정·박자 집계

0x02 비디오(JPEG) → 자세 집계

마디 경계 메시지 {"type": "measure", "measure_index": n}

마디 단위로 세 에이전트가 연주를 측정한다.
즉, measure json이 세 에이전트 측정의 트리거이다.

LiveSession (연주 한 건)

- **마디 윈도우** — 악보에서 뽑은 마디별 시간 구간
- **집계 모듈 3개** — 도메인별 스트림 버퍼링
- **엔진 3개** — 사용자의 Q-table을 DB에서 메모리로 전달

핵심 설계

마디 5번 측정, 마디 6번 측정 동시 실행 중일 때,
6번이 먼저 채점되는 경우, 마디 4 -> 마디 6 기준으로
reward가 측정됨. 학습 데이터가 무결하지 못함.
스레드풀에 워커를 1개만 뒀서 채점 순서 보장

측정부터 출력까지 - 개별 에이전트의 4-tier 계층 구조

계층	타입	담는 것
측정	MeasureReading	마디 번호 · 상태 · 수치 근거 · 유효 여부
액션	ActionSpec	액션 ID · 액션명 · 피드백 문구
정책	Policy	상태별 선택 가능 액션
출력	AgentOutput	도메인 · 마디 · 상태 · 액션 · reward · Q값 · meta

XX-00

슈퍼바이저 에이전트에게 위임
LLM 맞춤형 피드백

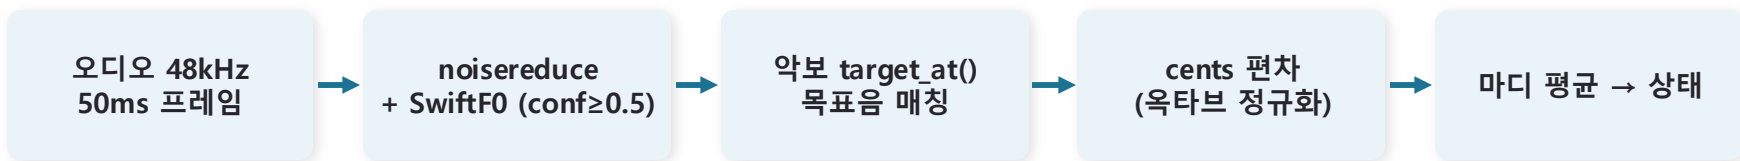
XX-01

GOOD

XX-02~

룰베이스 기반 상태에 따른 액션
케이스

음정 에이전트 - 목표 음과 cents 편차를 측정



$cents = 1200 \times \log_2(\text{실제Hz} / \text{목표Hz})$ 유효 프레임 5개(250ms) 미만인 마디는 valid=False

상태	조건 (avg_cents)	심각도
GOOD	편차 < 30	0
SHARP_SLIGHT / FLAT_SLIGHT	±30 ~ ±100	1
SHARP_MAJOR / FLAT_MAJOR	±100 이상	2

액션과 피드백

PT-02/03 음정 교정 “음정을 올리세요/내리세요”

PT-00 CALL_SUPERVISOR

박자 에이전트 - 기준 박자와의 어긋남(drift)을 측정

마디별 drift(ms)와 일치율 score를 구한다.

상태	조건 (위에서 아래로 판정)	심각도
GOOD	score ≥ 0.80 이고 $ \text{drift} \leq 80\text{ms}$	0
EARLY	$\text{drift} < -80\text{ms}$ (기준 박보다 빠름)	2
LATE	$\text{drift} > +80\text{ms}$ (기준 박보다 느림)	2
FAST	beat_ratio > 1.3 (템포 빠름)	1
SLOW	그 외 (템포 느림)	1

액션과 피드백

RH-02 기다리세요 (EARLY)

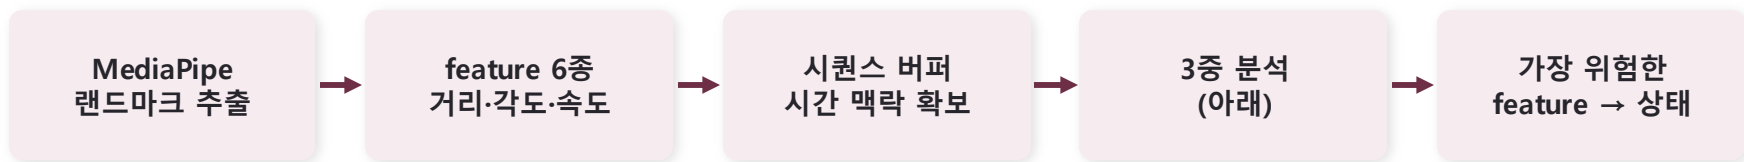
RH-03 따라잡으세요 (LATE)

RH-04 속도를 늦추세요 (FAST)

RH-05 속도를 높이세요 (SLOW)

RH-00 CALL_SUPERVISOR

자세 에이전트 - 6개 feature로 불안정 위치 측정



#	feature → 상태
0	왼손목-왼어깨 거리 → LEFT_HAND_ALIGNMENT
1	어깨 높이 차이 → SHOULDER_IMBALANCE
2	왼손목 속도 → LEFT_WRIST_MOVEMENT
3	왼팔 각도 → LEFT_ARM_POSTURE
4	오른팔 각도 → RIGHT_ARM_BOWING
5	오른손목 각도 → RIGHT_WRIST_ALIGNMENT

3 STEP 분석

- Logistic Regression — 나쁜 자세일 확률
- z-score — 좋은 자세 평균·표준편차 대비 이상치
- 방향성 규칙 — feature별 위험도 합산

final_score: <45 안정 · 45~70 불안정 · ≥70 위험

Q-learning - 이전 연주를 기억하고 개선된 피드백을 전달하기 위한 reward 구조

강화 학습 모델 적용

- epsilon 없음 — 항상 Q값이 가장 높은 액션
- $\alpha=0.1$, $\gamma=0.9$ / (state, action) $\rightarrow$ [q, count]

마디 n에 대한 마디 n+1의 상태 변화를 보고 reward를 계산한다.

마디 n+1의 변화	보상
GOOD으로 회복 (일반 액션)	+1.0
GOOD으로 회복 (위임 $\rightarrow$ 슈퍼바이저 적중)	+0.8
같은 그룹 안에서 심각도 호전	+0.5
변화 없음 (일반 액션)	-0.3
변화 없음 (위임 $\rightarrow$ 슈퍼바이저 소용 없음)	-0.5
심각도 악화	-0.8

개별 에이전트가 슈퍼바이저를 호출하는 기준

① 개별 에이전트 피드백이 소용없다

같은 상태가 반복
→ 변화 없음 -0.3이
계속 쌓인다



② Q값 역전

Q가
CALL_SUPERVISOR
초기값 0.0 보다 낮아진다



③ 슈퍼바이저로 위임

CALL_SUPERVISOR이 더
높은 값이 됐기 때문에
LLM이 원인 분석 시작



④ 결과에 따른 조정

적중 +0.8 → reward
소용없음 -0.5 → penalty