

TOY PROJECT :

KBO 승패 예측



3조 권도현 김형준 임주현 장하늘 정혜인 최진영 황종훈

주제 선정 및 동기



세이버매트릭스?!

기존의 선수 기록과 더불어 팀별 맞대결 데이터
기타 **승패에 영향을 미치는 다양한 요소들을 분석**하여,
KBO 경기의 승부를 예측할 수 있는 모델을 개발

KB Report 데이터 수집




www.kbreport.com 에서 기록된 데이터를 크롤링

설정한 누적 기간: 7일(6영업일)

분류1 날짜별 2024-07-24 ~ 2024-07-30 ↻

메인 기록	기본 기록	세부 기록
-------	-------	-------

#	팀명	경기	승	무	패	승률	기대승률	R/G	득점	홈런	도루	볼넷%	삼진%	BABIP	타율	출루율	장타율	OPS	wOBA	WAR
1	한화	3	3	0	0	1.000	-	6.00	18	2	0	6.7	11.7	0.304	0.286	0.339	0.429	0.768	0.337	-
2	KT	6	4	0	2	0.667	-	3.83	23	7	1	5.5	20.2	0.331	0.283	0.325	0.434	0.759	0.335	-
3	SSG	6	4	0	2	0.667	-	4.83	29	7	4	7.3	21.1	0.294	0.250	0.319	0.413	0.769	0.335	-
4	Hero	6	4	0	2	0.667	-	5.00	30	3	2	12.1	19.0	0.301	0.247	0.343	0.359	0.770	0.335	-
5	롯데	5	2	0	3	0.400	-	6.40	32	3	2	8.8	19.0	0.327	0.272	0.340	0.398	0.738	0.335	-
6	삼성	5	2	0	3	0.400	-	3.20	16	6	4	4.4	21.7	0.254	0.224	0.274	0.354	0.628	0.335	-
7	LG	3	1	0	2	0.333	-	5.33	16	3	2	12.3	16.9	0.310	0.269	0.375	0.398	0.773	0.335	-
8	KIA	6	2	0	4	0.333	-	5.17	31	9	0	7.7	18.1	0.287	0.265	0.335	0.459	0.794	0.335	-
9	두산	6	2	0	4	0.333	-	4.00	24	5	7	11.5	18.0	0.310	0.264	0.355	0.393	0.748	0.335	-
10	NC	6	2	0	4	0.333	-	4.33	26	5	2	11.2	23.8	0.305	0.239	0.348	0.378	0.726	0.335	-
	전체	26	26	0	26	0.500	-	9.42	245	50	24	8.8	19.3	0.303	0.259	0.335	0.401	0.736	0.335	-



데이터 전처리

기본 정보

팀 명	경기
-----	----

투수 관련 통계

투_승	투_패	투_세	투_홀드	투_블론	투_QS
투_이닝	투_타자	투_안타	투_2루타	투_3루타	투_홈런
투_실점	투_자책	투_삼진	투_볼넷	투_고4	투_HBP
투_폭투	투_보크	투_PK	투_도루	투_도실	투_삼진율
투_이닝당타자	투_볼넷율	투_ERA	투_FIP	투_WHIP	

데이터 전처리

타자 관련 통계

타_타석	타_타수	타_안타	타_단타	타_2루타	타_3루타
타_홈런	타_득점	타_타점	타_볼넷	타_고4	타_HBP
타_삼진	타_희플	타_희타	타_병살	타_도루	타_도실
타_타율	타_출루율	타_장타율	타_OPS	타_BABIP	

데이터 전처리

상대 팀 관련 통계

상대1

투_승1

투_패1

타_타석1

타_타수1

차_ERA

차_FIP

경기 위치 관련 통계

홈 경기 수

어웨이 경기 수

평균 관중 수

평균 이동거리


누적 이동거리

특성들은 팀의 성적과 각종 야구 지표를 통해 **팀의 경기력과 전략을 분석하는 데** 사용

모델링

ML Session에서 배운 모델들을 활용

- 로지스틱 회귀 분류
- 랜덤 포레스트
- 결정 트리 모델



cy: 0.4826
cy: 0.4803
cy: 0.4904
cy: 0.4893
cy: 0.5073
cy: 0.4848
cy: 0.4758
cy: 0.4972
cy: 0.4871
acy: 0.5140

Depth: 11, Cross-Validation Accuracy: 0.5174
Depth: 12, Cross-Validation Accuracy: 0.5252
Depth: 13, Cross-Validation Accuracy: 0.5084
Depth: 14, Cross-Validation Accuracy: 0.5050
Depth: 15, Cross-Validation Accuracy: 0.5118
Depth: 16, Cross-Validation Accuracy: 0.5151
Depth: 17, Cross-Validation Accuracy: 0.5196
Depth: 18, Cross-Validation Accuracy: 0.5107
Depth: 19, Cross-Validation Accuracy: 0.5084
Depth: 20, Cross-Validation Accuracy: 0.5084



Random Forest Cross-Validation Accuracy: 0.5095
Random Forest Test Accuracy: 0.4978

모델링 1차 분석

features

세이버메트릭스 상에서 많이 쓰이는 지표들

target은 다음 날의 결과로 설정 → 직전 7일(6경기)의 데이터로 당일 결과 예측

	KNN			Logi		계수					
	이웃		TRAIN	TEST	TRAIN	TEST	타_출루율	투_이닝당타	투_볼넷율	투_ERA	차_FIP
전체		10	0.63	0.58	0.53	0.48	0.046	0.026	0.034	-0.04	0.04

→ 예상보다 낮은 예측력 및 과적합 우려

모델링 보완 : 변수 간 상관관계 분석

[illegible]

모델링 보완 : 승리와 변수 사이 상관관계 분석

특성과승률상관관계	
	승률
승률	1
투_세	0.566151877294952
타_OPS	0.547789083392563
타_장타율	0.546423422528132
타_타점	0.504596789985938
타_득점	0.502538208678102
타_타율	0.493016186430828
차_OPS	0.486409013071466
차_장타율	0.474031437424162
타_출루율	0.450299253962526
차_타율	0.448146075750874
차_출루율	0.419970716151564
투_홀드	0.412887345447156
타_BABIP	0.378909406583045
타_2루타	0.338228262025035


모델링 보완

낮은 정확도 및 과적합 문제

특성 간 상관계수 분석 결과:

- 타자 관련 지표 간 상관관계 높음
- 투수(투구) 관련 지표 간 상관관계 낮음


➔ 데이터 추가 수집 및 사용할 변수 변경



추가 데이터 수집

- 선수 연봉 데이터
- 구단 별 지배회사(최대주주)의 자산가치 데이터
- 홈/어웨이 경기 여부
- 어웨이 시 이동 거리

승률 예측 대상의 개별 데이터



경기 상대방의 데이터 포함

상대와의 우위/열위 데이터 반영

모델링 2차 분석

로지스틱 회귀

	TRAIN	TEST	타_출루율	투_이닝당타	차_OPS	연봉차	차_타석	투_볼넷율	
KIA	0.68	0.76	0.381	0.054	-0.097	0.230	-0.580	0.082	
			차_장타율	차_OPS	자산차	연봉차	차_타석	차_ERA	
KT	0.64	0.64	-0.544	0.736	0.044	0.258	-0.158	-0.246	
			차_장타율	차_OPS	자산차	연봉차	차_타석	차_ERA	
LG	0.69	0.75	0.312	-0.205	0.677	-0.324	-0.061	0.112	
			차_장타율	차_OPS	자산차	연봉차	차_타석	투_볼넷율	안타/피안타
NC	0.62	0.57	-0.579	0.083	0.395	0.031	0.151	-0.470	0.548
			차_장타율	차_OPS	자산차	연봉차	차_타석	투_볼넷율	안타/피안타
SSG	0.63	0.57	-0.009	-0.455	-0.082	0.487	0.044	0.320	0.137
			차_장타율	차_OPS	자산차	연봉차	차_타석	투_볼넷율	안타/피안타
두산	0.65	0.58	0.179	-0.029	0.406	0.230	0.226	-0.446	-0.127
			차_장타율	차_OPS	자산차	연봉차	차_타석	투_볼넷율	안타/피안타
롯데	0.63	0.59	0.177	-0.453	-0.167	0.177	-0.285	0.458	0.120
			차_장타율	차_OPS	자산차	연봉차	투_볼넷율	차_타석	투_이닝당타
삼성	0.56	0.45	0.287	-0.210	0.092	-0.122	-0.219	-0.186	0.038
			차_장타율	차_OPS	자산차	연봉차	투_볼넷율		
키움	0.64	0.59	0.552	-0.379	-0.419	-0.124	0.525		
			차_장타율	차_OPS	연봉차	투_볼넷율	투_이닝당타자		
한화	0.64	0.5	0.365	0.103	-0.356	0.335	-0.008		

각각의 1, 2, 3위		
차_타석	타_출루율	연봉차
차_OPS	차_장타율	연봉차
자산차	연봉차	차_장타율
차_장타율	안타/피안타	투_볼넷율
연봉차	차_OPS	투_볼넷율
투_볼넷율	자산차	연봉차
투_볼넷율	차_OPS	차_타석
차_장타율	투_볼넷율	차_OPS
차_장타율	투_볼넷율	자산차
차_장타율	연봉차	투_볼넷율

모델링 2차 분석

로지스틱 회귀

팀별 연봉 차이와 자산 차이도 생각보다 많은 영향을 준다

각 팀마다 승리에 영향을 끼치는 주요한 요인들이 다를 수 있다

	TRAIN	TEST	타_출루율	투_이닝당타자 OPS	연봉차	차_타석	투_볼넷율	
KIA	0.68	0.76	0.381	0.054	-0.097	0.230	-0.580	0.082
			차_장타율	차 OPS	자산차	연봉차	차_타석	차 ERA
LG	0.69	0.75	0.312	-0.205	0.677	-0.324	-0.061	0.112
			차_장타율	차 OPS	자산차	연봉차	차_타석	투_볼넷율
SSG	0.63	0.57	-0.009	-0.455	-0.082	0.487	0.044	0.320
			차_장타율	차 OPS	자산차	연봉차	차_타석	투_볼넷율
두산	0.65	0.58	0.179	-0.029	0.406	0.230	0.226	-0.446
			차_장타율	차 OPS	자산차	연봉차	차_타석	투_볼넷율
롯데	0.63	0.59	0.177	-0.453	-0.167	0.177	-0.285	0.458
			차_장타율	차 OPS	자산차	연봉차	투_볼넷율	차_타석
삼성	0.56	0.45	0.287	-0.210	0.092	-0.122	-0.219	-0.186
			차_장타율	차 OPS	자산차	연봉차	투_볼넷율	투_이닝당타자
키움	0.64	0.59	0.552	-0.379	-0.419	-0.124	0.525	
			차_장타율	차 OPS	연봉차	투_볼넷율	투_이닝당타자	
한화	0.64	0.5	0.365	0.103	-0.356	0.335	-0.008	

각각의		
차_타석		
차 OPS		
자산차	연봉차	차_장타율
차_장타율	안타/피안티	투_볼넷율
연봉차	차 OPS	투_볼넷율
투_볼넷율	자산차	연봉차
투_볼넷율	차 OPS	차_타석
차_장타율	투_볼넷율	차 OPS
차_장타율	투_볼넷율	자산차
차_장타율	연봉차	투_볼넷율



의의

참고문헌의 Accuracy는 90% 수준

→ 이미 나온 결과를 분류해서 가능한 성과. 예측의 측면에서는 **자기실현적 예언**

→ 승리에 기여한 항목이 무엇인지는 파악할 수 있지만,
전날까지의 데이터를 바탕으로 추후 결과를 예측하기에 어려움이 있음

야구는 축구, 농구와 달리 월등한 1등은 없다

일부 팀별 결과 > 1위 승률(60.5%)




승률
0.605
0.552
0.533
0.504
0.496
0.475
0.475
0.472
0.458
0.427

한계

- 기본 가정의 유효성
 - 7일 간의 팀의 실적이 바로 다음날 이어진다는 가정의 이론적 타당성
- 선발투수 및 투수 정보에 대한 추가 고려
- 시간적 한계 및 방법론적 한계로 아직 최적의 feature를 찾지는 못함
- 교재를 바탕으로 공부한 간단한 수준의 모델만 사용
- 분석 결과로 나온 계수들에 대한 통계적 가설검정 필요

기대 효과



야구는 즐겁게 관람합시다 :)

